Universidad Nacional de Piura

Curso: Fundamentos Matemáticos de la IA

El Perceptrón Simple

Yofer Ticliahuanca

1. Introducción al Modelo de Neurona Artificial

La neurona artificial, también conocida como **Perceptrón de una sola capa**, constituye el bloque de construcción fundamental en el campo de las Redes Neuronales Artificiales. Este modelo matemático procesa un conjunto de entradas ponderadas para generar una respuesta binaria o continua mediante una función de transferencia.

1.1. Componentes del Modelo

El modelo matemático de la neurona se compone de los siguientes elementos esenciales:

1. **Vector de Entradas (X):** Representa las señales recibidas por la neurona. Se define como $X = [x_0, x_1, x_2, \ldots, x_n]^T$, donde $x_0 = 1$ representa el término de sesgo o *bias*.
2. **Vector de Pesos (W):** Modula la intensidad de cada conexión de entrada: $W = [w_0, w_1, w_2, \ldots, w_n]$. El componente w_0 es el peso asociado al *bias*.
3. **Suma Ponderada (S):** Es la combinación lineal de las entradas y los pesos.

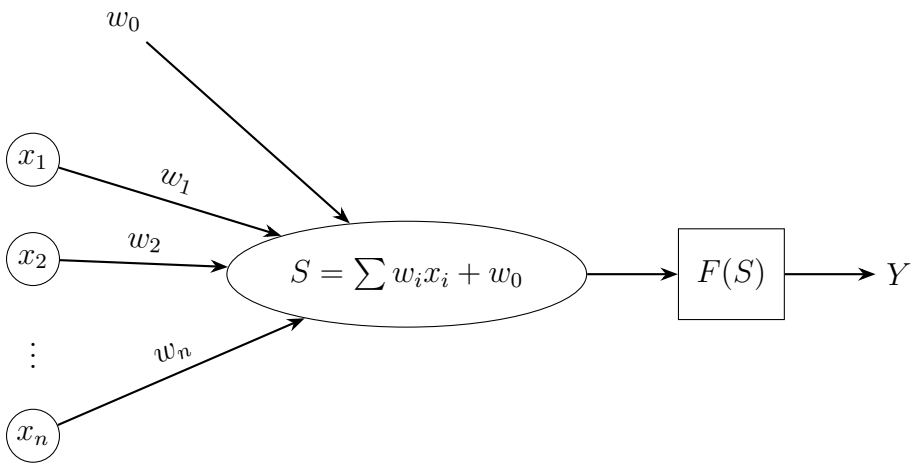


Figura 1: Modelo de una neurona artificial (Perceptrón).

1.2. Formulación Matemática de la Suma Ponderada

La suma ponderada S que procesa la neurona se define formalmente como el producto escalar entre el vector de pesos y el vector de entradas:

$$S = \sum_{i=0}^{n} w_i x_i = w_0 x_0 + w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$$

En notación matricial compacta, la suma ponderada se expresa como:

$$S = W \cdot X^T$$

1.3. Procesamiento de la Salida y Función de Activación

Una vez calculada la suma ponderada S, el valor resultante pasa a través de una **función de activación** $F(S)$ que determina el estado de la salida Y:

$$Y = F(S)$$

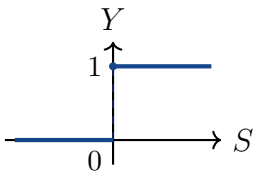
Detalle Intuitivo: El rol del Bias (w_0)

El parámetro w_0 (sesgo o *bias*) actúa como un umbral desplazable. Permite a la neurona desplazar la frontera de decisión fuera del origen en el espacio de entradas, incrementando la flexibilidad del modelo para adaptarse a diferentes distribuciones de datos.

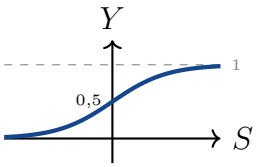
2. Funciones de Activación

La función de activación $F(S)$ transforma la suma ponderada S para determinar la salida Y de la neurona.

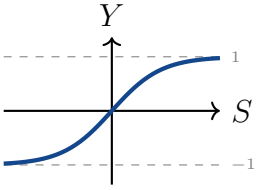
2.1. Funciones Elementales y sus Gráficas



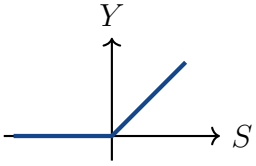
a) Escalón Unitario: $F(S) = \begin{cases} 1 & S \geq 0 \\ 0 & S < 0 \end{cases}$



b) Sigmoide: $\sigma(S) = \frac{1}{1+e^{-S}}$



c) Tangente Hiperbólica: $\tanh(S)$



d) ReLU: $F(S) = \max(0, S)$

Figura 2: Funciones de activación elementales.

2.2. Aplicaciones Prácticas

- **Escalón Unitario:** Utilizada en el Perceptrón clásico para problemas de clasificación binaria estricta (0 o 1).
- **Sigmoide (Logística):** Comprime la salida al rango $(0, 1)$, ideal para interpretar la salida como una probabilidad.
- **Tangente Hiperbólica** (tanh)**:** Centrada en cero con rango $(-1, 1)$.
- **ReLU:** Muy eficiente en cómputo para valores positivos.

2.3. Ejemplo 1: Evaluación de Patrones con Escalón Unitario

Dada una neurona artificial con función de activación escalón unitario, cuyos pesos son $w_1 = 0{,}5$, $w_2 = -0{,}3$ y umbral $w_0 = 0$:

$$Y = F(S) = \begin{cases} 1 & \text{si } S \geq 0 \\ 0 & \text{si } S < 0 \end{cases}$$

Determinar la salida Y para los patrones de entrada:

Tabla 1: Patrones de entrada.

Patrón	x_1	x_2
1	0.5	0.6
2	-1.2	2.8

Solución

La suma ponderada S para dos entradas sin sesgo está dada por:

$$S = w_1 x_1 + w_2 x_2$$

1. **Primer Patrón** ($x_1 = 0{,}5, x_2 = 0{,}6$)**:**

$$S = (0{,}5)(0{,}5) + (-0{,}3)(0{,}6) = 0{,}25 - 0{,}18 = 0{,}07 \implies Y = F(0{,}07) = 1$$

2. **Segundo Patrón** ($x_1 = -1{,}2, x_2 = 2{,}8$)**:**

$$S = (0{,}5)(-1{,}2) + (-0{,}3)(2{,}8) = -0{,}6 - 0{,}84 = -1{,}44 \implies Y = F(-1{,}44) = 0$$

Tabla 2: Resultados del Ejemplo 1.

x_1	x_2	S	**Salida** (Y)
0.5	0.6	0.07	1
-1.2	2.8	-1.44	0

3. Funciones Separables Linealmente

Un conjunto de patrones de entrenamiento se define como **linealmente separable** si existe un hiperplano (una línea recta en 2D, un plano en 3D, etc.) capaz de dividir el espacio de entradas en dos regiones distintas, separando completamente los patrones pertenecientes a una clase de los de la otra.

3.1. Ecuación de la Frontera de Decisión

En un espacio bidimensional (x_1, x_2), la frontera que divide las respuestas de la neurona se obtiene cuando la suma ponderada es igual a cero $(S = 0)$:

$$S = w_0 + w_1 x_1 + w_2 x_2 = 0$$

Despejando x_2 en función de x_1, se obtiene la ecuación de una recta en el plano:

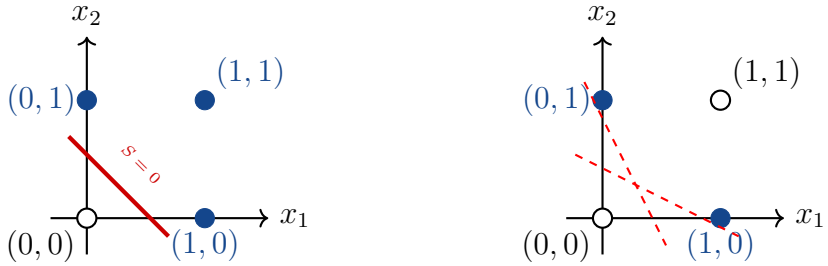
$$x_2 = -\frac{w_1}{w_2} x_1 - \frac{w_0}{w_2}$$

Donde:

- Pendiente de la recta: $m = -\frac{w_1}{w_2}$
- Intersección con el eje x_2: $b = -\frac{w_0}{w_2}$

3.2. Comparación Geométrica: Compuerta OR vs. Compuerta XOR

El Perceptrón simple solo puede resolver problemas que sean linealmente separables. A continuación se demuestra gráficamente esta limitación:



a) Función OR: **Linealmente Separable** b) Función XOR: **NO Separable**

Figura 3: Representación en el plano cartesiano x_1, x_2.

3.3. Criterio de Expresividad y Limitación

- **Capacidad del Perceptrón Simple:** Puede resolver funciones lógicas básicas como **AND**, **OR**, **NAND** y **NOR**, ya que todas sus combinaciones de salida se pueden dividir mediante una única recta.
- **Problema de la Compuerta XOR:** En la función XOR, las clases opuestas están dispuestas en las diagonales del cuadrado unitario. Es imposible trazar una sola recta que deje las salidas 1 de un lado y las salidas 0 del otro. Para solucionar esto se requiere un **Perceptrón Multicapa (MLP)**.

4. Algoritmo de Aprendizaje: Regla del Perceptrón

El objetivo del algoritmo de entrenamiento es ajustar iterativamente el vector de pesos W para que la neurona produzca la salida deseada Y_d frente a un conjunto de patrones de entrada.

4.1. Tipos de Aprendizaje

Los algoritmos de aprendizaje para una neurona se dividen principalmente en dos enfoques:

- **Corrección de Error:** Altera los pesos de la neurona después de la presentación de un patrón para corregir el error de salida.
- **Gradiente:** Modifica los pesos en dirección opuesta al gradiente de la función de error para minimizar el error cuadrático medio global.

4.2. Formulación de la Regla de Actualización

En el Perceptrón con función de activación limitador duro (escalón unitario), la actualización de pesos en la iteración k se rige por la ecuación:

$$W^{k+1} = W^k + \alpha \cdot e^k \cdot X^k$$

Donde:

- $W^k = [w_0^k, w_1^k, \ldots, w_n^k]^T$ es el vector de pesos actual.
- $X^k = [x_0, x_1^k, \ldots, x_n^k]^T$ es el vector de entradas (con $x_0 = 1$).
- $\alpha \in (0, 1]$ es la **tasa de aprendizaje** (o ratio de aceleración).
- e^k es el **error cometido** en el patrón k:

  $$e^k = Y_d^k - Y^k$$

  siendo Y_d^k la salida deseada y $Y^k = F(S^k)$ la salida calculada.

4.3. Comportamiento Intuitivo de la Regla

La regla del perceptrón responde a tres escenarios posibles al evaluar un patrón X^k:

1. **Respuesta Correcta ($e^k = 0$):** Si $Y^k = Y_d^k$, no se alteran los pesos:

   $$W^{k+1} = W^k$$

2. **Falso Positivo ($e^k = -1$):** La neurona devolvió $Y^k = 1$ y se esperaba $Y_d^k = 0$. Los pesos **se decrementan** para reducir la suma ponderada futura:

   $$W^{k+1} = W^k - \alpha \cdot X^k$$

3. **Falso Negativo** ($e^k = +1$)**:** La neurona devolvió $Y^k = 0$ y se esperaba $Y_d^k = 1$. Los pesos **se incrementan** para aumentar la suma ponderada:

$$W^{k+1} = W^k + \alpha \cdot X^k$$

Criterio de Parada y Convergencia

El algoritmo se ejecuta en ciclos denominados **Épocas** (evaluación completa de todos los patrones). El entrenamiento finaliza con éxito únicamente cuando el error $e^k = 0$ para todos los patrones de la época, lo que garantiza que el Error Cuadrático Medio total sea $E_{\text{RMS}} = 0$.

4.4. Ejemplo Práctico: Entrenamiento de la Compuerta OR

Se desea entrenar un perceptrón para aprender la función lógica OR con $\alpha = 1$ y pesos iniciales $W^1 = [1{,}5, 0{,}5, 1{,}5]^T$.

Época 1 (Paso a Paso por Patrón)

- **Patrón 1** ($X^1 = [1,0,0]^T, Y_d^1 = 0$)**:**

$$S^1 = (1{,}5)(1) + (0{,}5)(0) + (1{,}5)(0) = 1{,}5 \implies Y^1 = F(1{,}5) = 1$$

$$e^1 = 0 - 1 = -1 \implies W^2 = \begin{bmatrix} 1{,}5 \\ 0{,}5 \\ 1{,}5 \end{bmatrix} + (1)(-1) \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0{,}5 \\ 0{,}5 \\ 1{,}5 \end{bmatrix}$$

- **Patrón 2** ($X^2 = [1,0,1]^T, Y_d^2 = 1$)**:**

$$S^2 = (0{,}5)(1) + (0{,}5)(0) + (1{,}5)(1) = 2{,}0 \implies Y^2 = F(2{,}0) = 1$$

$$e^2 = 1 - 1 = 0 \implies W^3 = W^2 = \begin{bmatrix} 0{,}5 \\ 0{,}5 \\ 1{,}5 \end{bmatrix}$$

- **Patrón 3** ($X^3 = [1,1,0]^T, Y_d^3 = 1$)**:**

$$S^3 = 1{,}0 \implies Y^3 = 1, \quad e^3 = 0 \implies W^4 = W^3$$

- **Patrón 4** ($X^4 = [1,1,1]^T, Y_d^4 = 1$)**:**

$$S^4 = 2{,}5 \implies Y^4 = 1, \quad e^4 = 0 \implies W^5 = W^4$$

Evaluación Global de la Época 1

Tabla 3: Resultados al finalizar la Época 1 con $W = [0{,}5, 0{,}5, 1{,}5]^T$.

x_1	x_2	S	$Y = F(S)$	Y_d	$e = Y_d - Y$	e^2
0	0	0.5	1	0	-1	1
0	1	2.0	1	1	0	0
1	0	1.0	1	1	0	0
1	1	2.5	1	1	0	0

El Error Cuadrático Medio (E_{RMS}) al final de la Época 1 es:

$$E_{\text{RMS}} = \frac{1}{\text{NP}} \sum_{p=1}^{4} (e_p)^2 = \frac{1}{4}(1 + 0 + 0 + 0) = 0{,}25$$

Como $E_{\text{RMS}} \neq 0$, se requiere ejecutar épocas adicionales hasta lograr que todos los errores sean 0.

5. Conclusiones y Resumen Temático

A partir de la revisión teórica y los ejercicios prácticos desarrollados en este documento, se concluyen los siguientes aspectos fundamentales sobre el Perceptrón Simple:

- **Frontera de Decisión Lineal:** La neurona artificial con función de activación escalón actúa como un clasificador lineal, dividiendo el espacio de entradas mediante un hiperplano definido por la ecuación $S = W \cdot X^T = 0$.
- **Garantía de Convergencia:** El teorema de convergencia del Perceptrón asegura que el algoritmo de aprendizaje encontrará un conjunto de pesos válido en un número finito de pasos, siempre y cuando los datos de entrenamiento sean estrictamente **linealmente separables**.
- **Limitaciones Estructurales:** Redes de una sola capa son incapaces de resolver problemas no lineales como la función lógica **XOR**. Esta limitación histórica motivó el desarrollo de arquitecturas más complejas, como el **Perceptrón Multicapa (MLP)** y los algoritmos de retropropagación (*Backpropagation*).

Cuadro Sinóptico: Elementos Clave

Suma Ponderada: $S = \sum_{i=0}^{n} w_i x_i = W \cdot X^T$

Fórmula de Error: $e^k = Y_d^k - Y^k$

Regla de Actualización: $W^{k+1} = W^k + \alpha \cdot e^k \cdot X^k$

Criterio de Parada: Error Cuadrático Medio $E_{\text{RMS}} = 0$